量子随机数池：
用含噪云端量子真机无损驱动大语言模型解码

基于逻辑比特云 QZ03 超导量子处理器与 stories15M 预训练模型

2026 年 11 月

摘要

在整条大语言模型（LLM）推理流水线中，随机数是**唯一一个硬件噪声不构成错误**的环节——噪声只表现为比特偏置，可由提取器完全消除。据此我们让一台含噪、未纠错的小型云端量子真机，第一次端到端驱动真实预训练 LLM 的解码：QPU 离线产生随机比特、经 Toeplitz 提取入池，采样器逐 token 取用，GPU 前向不变、秒级 QPU 延迟不进入推理路径。这同时关闭两道缺口：生产系统默认的伪随机数可由输出反推（我们实测观测 624 个输出即 100% 逐字复现后续生成），以及进入算力中心的量子算力在推理中无处落地。在逻辑比特云 QZ03（35 物理比特、无纠错）上驱动 stories15M：原始真机比特 NIST SP 800-22 检验通过 2/11、提取后 **11/11 全部通过**；采样的分布保真度与多样性和 MT19937、CSPRNG 一致（token 频率相关 0.997–0.998），为**无损替换**；物理来源使上述预测攻击退化为盲猜；单台设备支撑 约 **1500 token/s** 的解码采样。据我们所知，这是通用云端门模型量子真机首次端到端驱动真实预训练 LLM 解码、并完成随机性—安全—吞吐—成本全链路评测的公开案例。

1 引言

在整条 LLM 推理流水线中，随机数是**唯一一个硬件噪声不构成错误**的环节。矩阵乘里噪声逐层累积、结果崩坏（附录 A：单注意力头打分与精确值相关系数仅 0.52）；而随机数本就是量子测量的原生产物，噪声在此只表现为比特偏置，只要估出最小熵，提取器就能把它**完全消除**。据此我们让一台 35 物理比特、未纠错的云端量子真机，第一次端到端 驱动真实预训练 LLM 的解码：QPU 离线产生随机比特，经 Toeplitz 提取入池，采样器逐 token 取用；GPU 前向不变，秒级 QPU 延迟不进入推理路径（§3，图 1）。

这一个切入点同时回答两道现实缺口。**其一，生成的核心是采样**：温度 > 0 时每个 token 都由一个随机数在分布 上反查决定，而在线 LLM 默认用伪随机数（MT19937 即 NumPy/PyTorch CPU 默认），其状态可由输出反推—— §4.3 我们实测观测 624 个输出即可 100% 逐字复现后续生成，这是部署在生产里、从未在**源头**关闭 的信任缺口。**其二，进入算力中心的量子算力在推理里无处落地**：把矩阵乘搬上量子线路，逐字复现每位置约需 4.4×10^{10} shots（附录 A）、容错编译每 token 约 2×10^{10} Toffoli，今天走不通。用物理测量产生 解码随机数恰落在两缺口交点——无种子、无可反推状态，从源头堵上其一；含噪小机即可胜任，落实其二。

现有把量子随机数接入 LLM 的工作，或依赖专用光子硬件 [1]、或停留在玩具词表 [2]、或未经系统评测 [3]。据我们所知，这是**通用云端门模型量子真机首次端到端驱动真实预训练 LLM**（而非玩具、非模拟器、非专用光子）的解码。在逻辑比特云 QZ03 上驱动 stories15M，取得四项结果：

- **含噪比特变为合格随机源**（§4.1）：原始比特“为 1”的频率为 0.452、NIST 检验通过 2/11；经流水线提取后频率 0.501，**11/11 全部通过**。
- **无损即插即用**（§4.2）：分布保真度（卡方、KS、总变差）与生成多样性均与 MT19937、CSPRNG 一致，token 频率相关系数 0.997–0.998。
- **从源头消除状态还原攻击面**（§4.3）：对推理栈默认的 MT19937，观测 624 个输出即可 100% 预测后续 token；量子随机数池无状态可窃、无种子可泄，攻击者降至盲猜基线。
- **单台设备吞吐够用**（§4.4）：35 比特 QZ03 的纯执行产率为 2.40×10^4 可用 bit/s，可支撑约 1500 token/s 的解码采样。

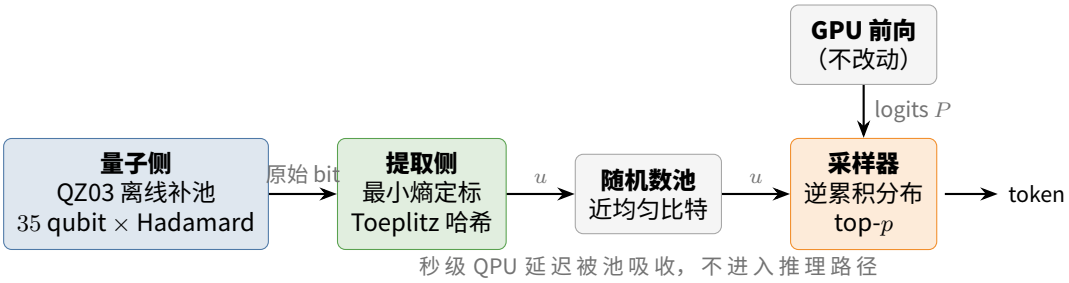


图 1: 量子随机数池架构。量子侧与提取侧离线补池；采样器消费池中均匀数，与不改动的 GPU 前向并行； QPU 延迟不在推理关键路径上。

2 相关工作

量子随机数（QRNG）用于 LLM。 与本文最接近的是 Seed Hijacking 一文 [1]：它提出对 LLM 采样的 种子劫持攻击，并用**专用光子** QRNG 卡（PCIe、预取数千万浮点数构成内存池）做防御，接入 GPT-2/Qwen2/DeepSeek， 实测该池化方案的中位延迟开销约 0.6%。其硬件是专用光子器件而非通用量子处理器，且未报告生成质量的统计检验。 此外，有在云端门模型量子机 QuTech Tuna-9 上驱动 8 词词表玩具模型的演示 [2]，把 QRNG 作为采样插件的 工程尝试 [3]，以及在 IBM 云超导设备上做 QRNG 的早期研究 [4]。

可认证随机性。 JPMorganChase 与 Quantinuum 在 56 比特囚禁离子机 H2 上实现了基于随机电路采样的 可认证随机性，用超算验证，产出信息论意义上可证明的新鲜随机性 [5]。这类工作要求电路规模足以抵抗 经典模拟，硬件与验证代价极高。

本文定位。 我们把一台**通用的、基于门模型的云端量子真机**用作随机数源，端到端驱动一个**真实预训练 LLM**（而非玩具词表）的解码，并给出随机性检验、与伪随机数的质量对照、安全攻防及吞吐/成本的 全链路真机实测。其中种子劫持攻击的思路取自 [1]，本文在自己的门模型真机链路上复现并量化其后果。

3 系统设计

整体架构把“产生随机数”与“消费随机数”解耦为三级流水线（图 1）：

1. **量子侧（离线补池）**： 在 QZ03 上重复执行“对 35 个物理比特各加一个 Hadamard 再测量”的电路， 每条电路 1000 shots、产 35×1000 个原始比特。平台 SDK 在测量前插入读出校正门（`x21`）， 结果以 per-shot 位串（memory）返回。
2. **提取侧（去偏）**： 先做逐比特偏置与最小熵评估，再用 **Toeplitz 矩阵哈希**这一**强随机性 提取器**把带偏置、弱相关的原始比特压缩成接近理想均匀的输出（剩余哈希引理保证输出与均匀分布的统计距离 $\leq \varepsilon$，代价为损失 $2\log_2(1/\varepsilon)$ 比特）。
3. **消费侧（解码）**： 经典前向给出下一 token 的 logits，经温度与 top-p 截断得到分布 P；从池中取 一个均匀数 $u \in [0, 1)$，用逆累积分布 $t = \min\{k : \sum_{i \leq k} P_i > u\}$ 完成采样。每 token 消耗一个 16-bit 均匀数。

4 实验

平台：逻辑比特云 QZ03 超导量子处理器，35 个**物理比特**、网格拓扑、未做量子纠错（NISQ）；CZ 两比特门保真度约 0.99–0.996，读出采用 measure2 方案。正因为是未纠错的物理比特，其原始读出才带有可观偏置 （§ 4.1），而这恰好落在提取器可消除的维度上。模型：stories15M（Karpathy 的 llama2.c 预训练模型，1.52×10^7 参数， dim 288 / 6 层 / 6 头 / 词表 32000），**不重新训练**。

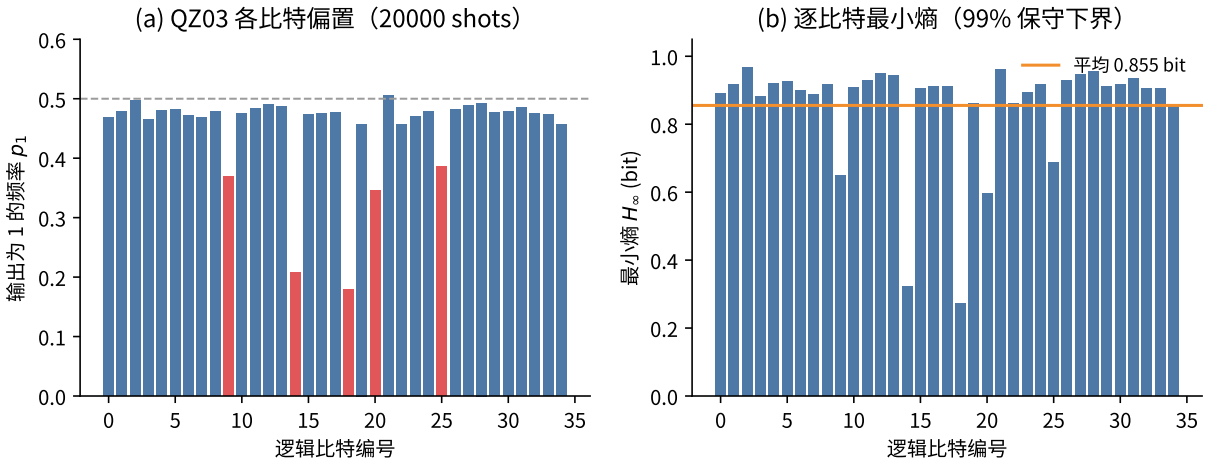


图 2: 提取前的原始偏置（a）与保守最小熵（b）：流水线据此确定 0.785 的提取率。红色为偏离 0.5 超过 0.05 的比特。

表 1: NIST SP 800-22 子集 p 值（$p \geq 0.01$ 视为通过）。

检验项	原始真机比特	Toeplitz 提取后
单比特频数 (Frequency)	0.0000	0.1007
块内频数 (Block Frequency)	0.0000	0.5482
游程 (Runs)	0.0000	0.7900
块内最长游程 (Longest Run)	0.0000	0.4954
二元矩阵秩 (Matrix Rank)	0.0681	0.0694
离散傅里叶谱 (DFT)	0.0000	0.6864
累加和-正向 (Cusum fwd)	0.0000	0.0225
累加和-反向 (Cusum bwd)	0.0000	0.1884
序列 (Serial) 1	0.0000	0.8584
序列 (Serial) 2	0.2475	0.8287
近似熵 (Approx. Entropy)	0.0000	0.7864
通过数	**2/11**	**11/11**

4.1 含噪比特经提取通过全部随机性检验

数据集：QZ03 上 20 条任务（每条 35 比特 $\times$ 1000 shots），共 2×10^4 次测量、7×10^5 原始比特。

待消除的偏置。 原始比特存在读出偏置——总体“为 1”频率 0.452，最低单比特 $p_1 = 0.179$（图 2a）；这正是提取环节要消除的对象。按 $H_\infty = -\log_2 \max(p_0, p_1)$ 估计逐比特最小熵，并对 $p_{\max}$ 取 99% 置信上界得**保守**下界（图 2b），最小熵率保守为 **0.855 bit/bit**，提取率即据此确定。

Toeplitz 提取。 取 $\varepsilon = 2^{-100}$、输入块 7000 bit、留 5% 工程余量，设输出 5496 bit/块，提取率 **0.785**；对 100 个块共提取 5.496×10^5 比特，“为 1”频率回到 **0.5011**。

随机性检验。 在等长前缀（5.49×10^5 bit）上对原始与提取后比特各跑 NIST SP 800-22 [6] 的 11 项（表 1、图 3）：原始比特通过 2/11，**提取后 11/11 全部通过**。标准提取环节把真机读出偏置完整转化为合格随机源。

4.2 无损即插即用：质量与伪随机数一致

把三种随机源——量子随机数池（QRNG）、梅森旋转（MT19937，Python 标准库）、操作系统密码学随机数（CSPRNG，`os.urandom`）——统一量化为 16-bit 均匀数，接入 stories15M 的 top-p 采样（提示“Once upon a time, there was a little”，温度 1.0，top-p 0.9）。

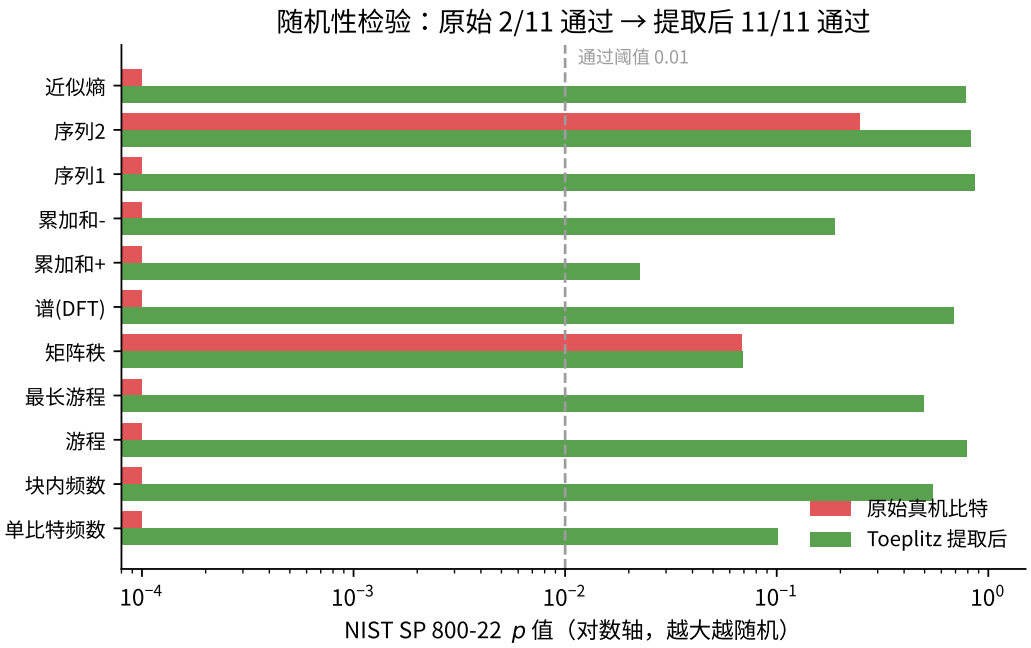


图 3: NIST SP 800-22 子集 p 值（对数轴）。提取把 2/11 通过提升到 11/11 通过。

表 2: 分布保真度（$N = 1.5 \times 10^4$ 次抽样）。TV 的判据是理想采样噪声底，非源间比较。

随机源	卡方 p	KS p	总变差 TV
QRNG（QZ03 真机池）	0.562	0.875	0.0044
MT19937	0.944	0.113	0.0014
CSPRNG	0.361	0.505	0.0033
理想采样（参照）	—	—	0.0043 $[0.0013, 0.0093]$

分布保真度。 对首个新 token 的定分布 P，用三种源各抽 1.5×10^4 次。采样误差的参照系是**理想 采样本身的噪声底**：同样次数的理想多项抽样，其与 P 的总变差距离均值为 0.0043、95% 区间 $[0.0013, 0.0093]$。三种源的总变差全部落在该区间内，量子池的 0.0044 正是理想采样的典型值（表 2）。卡方与 KS 的 p 值用于判断是否通过（均 $\gg 0.01$），不用于源间排名。

生成多样性。 量子随机数池保持了与 PRNG/CSPRNG 相同的生成多样性。三种源各生成 500 条长 20 的续写， distinct-n 与唯一续写占比一致，任意两源的 token 频率相关系数达 0.997–0.998（表 3）。

小结： 把采样随机源换成量子真机，分布保真度、多样性与 token 频率均与成熟 PRNG/CSPRNG 一致， 不付出任何质量代价。

4.3 关闭采样信任缺口：实证

本节给出 § 1 缺口一的实证闭环：先把“默认采样可被预测”从隐患坐实为可执行的攻击，再证明量子随机数池从**源头** 把它关闭。

缺口是真实可利用的。 MT19937 是 Python 标准库与 PyTorch CPU 端的默认随机源、也是 NumPy 旧版接口的 默认算法，其内部状态是 624 个 32-bit 字；观测到 624 个连续输出后，逐个做 tempering 逆变换即可还原状态，预测 此后**全部**输出。在 LLM 场景里，这意味着攻击者能预测、乃至操纵模型将采样出的 token。该攻击思路由 [1] 提出，我们在门模型真机链路上首次把它贯通到生成端并量化其后果。

实测（图 4）：采样源为 MT19937 时，攻击者观测 624 个 32-bit 输出后，

· 对随后 200 个随机数的预测命中率 **100%**（200/200）；

表 3: 生成多样性（每源 500 条、长 20 的续写）。

随机源	distinct-1	distinct-2	distinct-3	唯一续写占比
QRNG（QZ03 真机池）	0.060	0.166	0.259	0.844
MT19937	0.058	0.162	0.249	0.828
CSPRNG	0.059	0.165	0.257	0.846
token 频率相关：QRNG–MT19937 0.997；QRNG–CSPRNG 0.998；MT19937–CSPRNG 0.998				

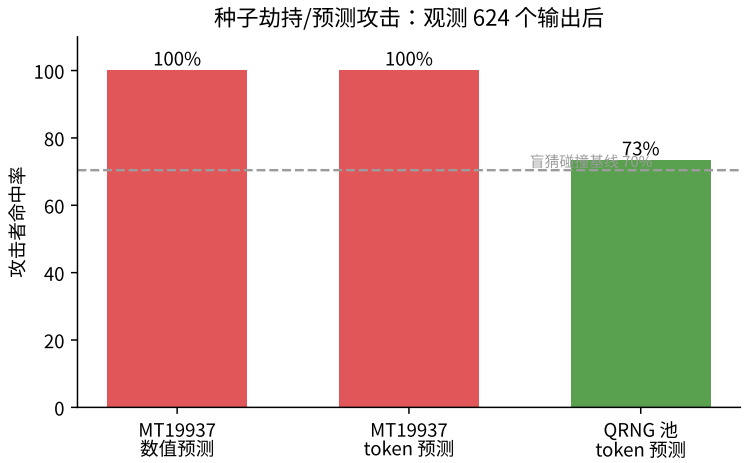


图 4: 种子劫持/预测攻击。观测 624 个输出后 MT19937 被 100% 预测；量子随机数池下攻击者命中率落在分布自身的 盲猜基线（虚线）。

· 对随后 30 个**生成 token** 的预测命中率 **100%**（30/30），逐字复现受害者的生成：“girl named Lily. She loved going to the park with her mom and dad...”。

量子随机数池把它关闭。 换成 QZ03 真机随机数池后，攻击者无法从历史比特还原任何状态，对随后 token 的 命中率为 73.3%，与“仅知道分布、盲猜”的碰撞基线 $\mathbb{E}\sum_i P_i^2 = 70.4\%$ 无统计差异（二项检验 $p = 0.84$）[1]。即攻击者**退化到只能盲猜**， 缺口被关闭。

威胁模型与定位。 物理随机源从**源头**消除了这一类攻击面：它没有可还原的内部状态，也没有需要保密的 种子。密码学安全伪随机数生成器（CSPRNG）同样能抵抗状态还原，其安全性建立在种子保密与计算困难性假设之上； 量子随机数池的安全性则来自测量这一物理过程本身。二者对应不同的信任模型——量子源的特点是**无状态可窃、 无种子可泄**。

4.4 吞吐：单台设备支撑约 1500 token/s

20 条任务的真机计量（平台返回的 `execution_time` 与墙钟时间戳）给出表 4。

吞吐不构成瓶颈。 单台 35 比特 QZ03 的纯执行产率已足以支撑约 1500 token/s 的解码采样，并对维持 1000 token/s 留有余量；池化设计把秒级 QPU 延迟与推理解耦，采样本身只是一次查表。**增量利用已部署的 量子算力。** 对已拥有量子算力的算力中心，本方案以每兆比特约 ¥364 的实测单价，让通用量子处理器在 LLM 推理 流程中承担确定的生产性负载，无需新增专用硬件，且对生成质量无损。

5 适用范围与定位

· **随机性保证的来源。** 本文的随机性由 NIST SP 800-22 检验与 Toeplitz 提取器的剩余哈希引理保证。 基于随机电路采样的可认证随机性 [5]要求电路规模足以抵抗经典模拟并配合第三

[1]碰撞基线由模型在该提示下的输出分布决定，与随机源无关。

表 4: QZ03 随机数产出的吞吐、延迟与成本（20 条任务实测）。

指标	数值
每条任务纯执行时间	1.15 ± 0.24 s（产 35000 原始 bit）
补池延迟（后台进行，不在推理路径上）	1.4 s（范围 1–2 s）
纯执行吞吐（原始 / 提取后）	3.06×10^4 / 2.40×10^4 bit/s
可支撑的解码采样速率	**≈ 1500 token/s**（16 bit/token）
维持 1000 token/s 所需原始产率	2.04×10^4 bit/s（低于实测产率，留有余量）
总成本 / 单位成本	¥200（5.50×10^5 提取 bit）/ ¥364 每 Mbit

方验证，35 比特 QZ03 的电路可被经典模拟，因此本文不以可认证随机性为目标，二者是正交的两个方向。

- **提取器种子**。 Toeplitz 矩阵由一段公开种子定义，本文由操作系统 CSPRNG 生成；对端到端量子来源 有要求的部署，可改用独立可信随机源生成种子，流水线其余部分不变。
- **与模型规模无关的接口**。 随机数池只向采样器提供均匀数，与模型的参数量和结构无关，因此 stories15M 足以验证从量子真机到生成 token 的完整链路。

6 结论

解码采样是 LLM 推理中天然对量子硬件噪声鲁棒的一环。基于这一观察，量子随机数池让一台 35 比特的含噪云端真机 端到端驱动预训练 LLM 的解码：含噪比特经提取通过全部 NIST 检验，生成质量无损，状态还原攻击面从源头消除， 单台设备的吞吐即可支撑约 1500 token/s。据我们所知，这是通用云端门模型量子真机首次端到端服务真实预训练 LLM 推理。在算力紧缺、同时拥有量子算力的现实设定下，**量子随机数池**是把量子算力接入 LLM 推理最轻量、最鲁棒、 最直接的落点。

A 计算路径的代价

本附录量化“把前向计算也搬上量子线路”的资源代价，支撑引言中“计算这条路今天走不通”的判断。我们把 stories15M 的 **每一次矩阵-向量乘**（含注意力的 $q \cdot k$、$p \cdot V$）写成量子干涉线路：用形如 $\frac{1}{\sqrt{2R}} \sum_j |j\rangle(|0\rangle|\hat{x}\rangle + |1\rangle|\hat{m}_j\rangle)$ 的叠加态， 对辅助比特做 Hadamard 后测量，$P(j,0) - P(j,1) = \langle \hat{x}|\hat{m}_j\rangle / R$ 即给出内积（RMSNorm 增益与 RoPE 旋转并入权重）。在 Qiskit Aer 上：精确概率时 30/30 个 token 与经典逐字一致；每行 10^6 shots （每位置 4.4×10^{10} shots）时仍 30/30 一致，10^5 时第 25 个 token 起偏离——**逐字复现的 shots 代价达** 10^{10} **量级**，这是计算路径不可行的根本原因。

在 QZ03 真机上实测第 0 层第 0 个注意力头的打分（48 维内积拆成 12 段 4 维 Hadamard 测试、10 段并行）： 单段 4 维余弦与理想值相关系数 0.90；合成 48 维打分相关系数 0.52、注意力分布总变差 0.55，而送回模型后下一个 词分布与精确值的总变差仅 0.017（单个低层头的误差被模型吸收）。即便单头误差可被吸收，逐字复现整条前向所需的 shots 规模仍远超解码随机数——两相对照，解码随机数池才是当下最直接可用的接入点。

复现

配套代码与数据随本文提供：真机 QRNG 原始比特（`qz03_qrng_raw.json`，含 20 条任务 ID 与时间戳）、 随机性分析与提取（`analyze_qrng.py`、`nist_sts.py`）、采样对照（`qsample.py`）、攻防演示（`attack.py`）、吞吐成本（`throughput.py`）、全前向量子化（`qfull.py`）。 真机平台：逻辑比特云（`cloud.logicalqubit.com`，SDK `lqcloud`）。

参考文献

[1] Seed Hijacking of LLM Sampling and Quantum Random Number Defense. arXiv:2605.08313 (2026).

[2] Quantum exordium for natural language processing: sampling on decoders, validated on QuTech Tuna-9 (T-9) hardware（8 词词表玩具演示）.

[3] Quantum-random vLLM sampler (qr-sampler). `github.com/alchemystack/Quantum-random-vLLM-sampler`.

[4] K. Tamura, Y. Shikano. Quantum Random Numbers generated by the Cloud Superconducting Quantum Computer. arXiv:1906.04410 (2019).

[5] Certified randomness using a trapped-ion quantum processor (JPMorganChase & Quantinuum H2, 56 qubits). Nature (2025).

[6] A. Rukhin et al. A Statistical Test Suite for Random and Pseudorandom Number Generators. NIST SP 800-22 Rev. 1a (2010).

[7] M. Turan et al. Recommendation for the Entropy Sources Used for Random Bit Generation. NIST SP 800-90B (2018).