量子随机数池：
用含噪云端量子真机无损驱动大语言模型解码

基于逻辑比特云 QZ03 超导量子处理器与 stories15M 预训练模型

2026 年 11 月

摘要

含噪、未纠错的量子处理器（QPU）难以承担大语言模型（LLM）推理中的矩阵运算，但解码采样所需的随机数有一个不同的性质：硬件噪声在这里不构成计算错误，而是表现为比特偏置与弱相关，可由随机性提取器消除。据此我们构建量子随机数池：QPU 离线产生原始比特，经 Toeplitz 哈希提取后存入池中，采样器逐 token 取用；GPU 前向计算不变，秒级的 QPU 延迟不进入推理关键路径。我们在逻辑比特云 QZ03（35 个物理比特，未纠错）上用该方案驱动预训练模型 stories15M 的解码。原始比特只通过 NIST SP 800-22 所测 11 项检验中的 2 项，提取后 11 项全部通过；生成的分布保真度与多样性和梅森旋转（MT19937）及密码学安全伪随机数生成器（CSPRNG）相比未检出差异，token 频率相关系数为 0.997 – 0.998。对默认的 MT19937，攻击者观测 624 个输出即可逐字预测后续生成；换用量子随机数池后，其命中率降至盲猜基线。按纯执行时间计，单台 QZ03 可支撑约 1500 token/s 的解码采样，实测成本约 ¥364/Mbit。结果表明，当前的含噪量子硬件已能在 LLM 推理中承担一项不损失生成质量的功能；其随机性由统计检验与提取器理论保证，而非可认证随机性。

1 引言

量子处理器（QPU）正在进入算力中心，但在大语言模型（LLM）推理中，它们目前难以承担有用的计算。把前向计算搬上量子线路，噪声会逐层累积：在 QZ03 上实测单个注意力头的打分，与精确值的相关系数仅为 0.52；即便在只有采样噪声的模拟中，逐字复现生成结果每个位置也约需 4.4×10^{10} shots（附录 A）。若改用容错量子计算，每个 token 约需 2×10^{10} 个 Toffoli 门。由此产生一个实际的问题：推理流水线中是否存在某个环节，能够容忍今天量子硬件的噪声？

解码采样是一个例外。温度大于 0 时，每个 token 都由一个均匀随机数在输出分布上反查决定。随机数本就是量子测量的原生产物：硬件噪声在这里不构成计算错误，而是表现为比特偏置与弱相关；只要能可靠估计最小熵，随机性提取器就能把原始比特压缩为与均匀分布统计距离任意小的输出。随机数的来源还关系到生成的安全性。在线推理栈默认使用伪随机数生成器（PRNG），例如 Python 标准库与 PyTorch CPU 端默认的梅森旋转算法 MT19937，其内部状态可由输出反推；文献 [1] 据此提出针对 LLM 采样的种子劫持攻击，并以专用光子量子随机数发生器（QRNG）作为防御。

现有把量子随机数接入 LLM 的工作，或依赖专用光子硬件 [1]，或只在玩具词表上演示 [2]，或缺少系统评测 [3]（§ 2）。因此仍不清楚：一台通用、含噪、未纠错的门模型 QPU，能否为真实预训练 LLM 的解码供给随机数——提取后的比特能否通过标准随机性检验，生成质量是否与伪随机数相当，能否抵御基于输出的状态还原攻击，吞吐与成本又处于什么水平。

本文在真机上回答这一问题。我们提出量子随机数池（§ 3，图 1）：QPU 离线产生原始比特，经 Toeplitz 哈希提取后存入池中，采样器逐 token 取用；GPU 前向计算不变，秒级的 QPU 延迟被池吸收。我们在逻辑比特云 QZ03 上用它驱动 stories15M 的解码，得到四项结果：

- **含噪比特经提取通过标准检验**（§ 4.1）：原始比特只通过所测 11 项 NIST SP 800-22 检验中的 2 项，Toeplitz 提取后 11 项全部通过。
- **生成质量与伪随机数相当**（§ 4.2）：分布保真度与生成多样性和 MT19937、密码学安全伪随机数生成器（CSPRNG）相比未检出差异。
- **抵御状态还原攻击**（§ 4.3）：MT19937 驱动的生成可被逐字预测，量子随机数池使攻击者降至盲猜基线；CSPRNG 同样能抵御该攻击，二者的区别在于信任模型。

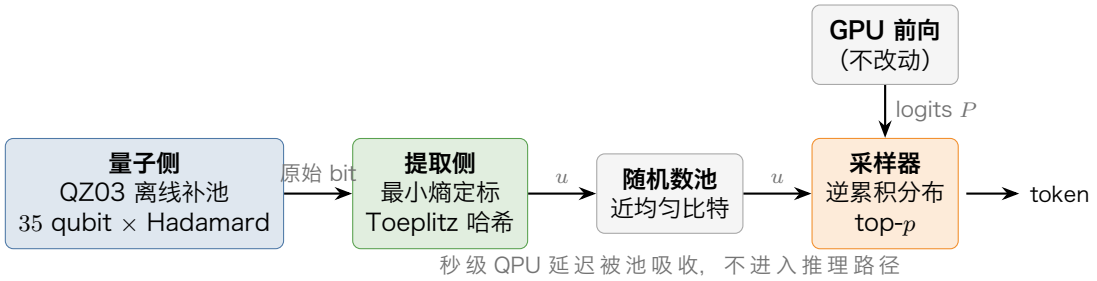


图 1: 量子随机数池架构。量子侧与提取侧在后台补池；采样器从池中取均匀数，结合不改动的 GPU 前向计算给出的 logits 完成采样。QPU 延迟因此不在推理关键路径上。

- **单台设备吞吐够用**（§ 4.4）：按纯执行时间计，单台 QZ03 可支撑约 1500 token/s 的解码采样，单价约 ¥364/Mbit。

据我们所知，这是通用门模型 QPU 首次端到端驱动真实预训练 LLM（而非玩具词表）的解码。

2 相关工作

量子随机数用于 LLM。 与本文最接近的是文献 [1]：它提出针对 LLM 采样的种子劫持攻击，并以专用光子 QRNG 卡（PCIe 接口，预取数千万个浮点数构成内存池）作为防御，接入 GPT-2、Qwen2 与 DeepSeek，实测该池化方案的中位延迟开销约 0.6%。该方案依赖专用光子器件而非通用量子处理器，且未报告生成质量的统计检验。此外，文献 [2] 在云端门模型 QPU QuTech Tuna-9 上驱动了 8 词词表的玩具模型，文献 [3] 把 QRNG 实现为 vLLM 的采样插件，文献 [4] 较早研究了用 IBM 云端超导设备生成量子随机数。这些工作都没有在通用门模型 QPU 上，对真实预训练模型的解码做随机性、生成质量、安全与吞吐的系统评测。本文沿用文献 [1] 的攻击思路，在门模型 QPU 链路上复现并量化其后果（§ 4.3）。

可认证随机性。 JPMorganChase 与 Quantinuum 在 56 比特囚禁离子 QPU H2 上，基于随机电路采样实现了可认证随机性，借助超算验证，产出信息论意义上可证明新鲜的随机数 [5]。这类方案要求电路规模足以抵抗经典模拟，硬件与验证代价都很高；本文的 35 比特电路可被经典模拟，因此不以可认证随机性为目标（§ 5）。

3 系统设计

量子随机数池把“产生随机数”与“消费随机数”解耦为三级流水线（图 1）。补池在后台进行，秒级的 QPU 延迟由池吸收；采样器每次只从池中取一个数，因此 QPU 不进入推理的关键路径。

1. **量子侧（离线补池）**：在 QZ03 上重复执行同一电路——对 35 个物理比特各施加一个 Hadamard 门后测量。每条电路 1000 shots，产生 35×1000 个原始比特。平台 SDK 在测量前插入读出校正门（`x21`），结果以逐 shot 位串（memory 格式）返回。
2. **提取侧（去偏）**：先逐比特估计偏置与最小熵，再用 Toeplitz 矩阵哈希（一种强随机性提取器）把带偏置、弱相关的原始比特压缩为近均匀的输出。由剩余哈希引理，只要输入块的最小熵估计成立，输出与均匀分布的统计距离不超过 ε，代价是损失 $2\log_2(1/\varepsilon)$ 比特。Toeplitz 矩阵由一段公开种子定义，本文用操作系统的 CSPRNG 生成。
3. **消费侧（解码）**：经典前向计算给出下一个 token 的 logits，经温度缩放与 top-p 截断得到分布 P；从池中取一个 16-bit 均匀数 $u \in [0, 1)$，按逆累积分布 $t = \min\{k : \sum_{i \le k} P_i > u\}$ 完成采样。每个 token 消耗一个 16-bit 均匀数。

4 实验

实验平台为逻辑比特云的 QZ03 超导 QPU：35 个物理比特，网格拓扑，未做量子纠错；CZ 两比特门保真度约 0.99 – 0.996，读出采用 measure2 方案。由于使用未纠错的物理比特，原始读出带有明显偏置（§ 4.1），而偏置正是提取器能够消除的。模型为 stories15M（Karpathy 的 llama2.c 预训练模型，1.52×10^7 参数，维度 288、6 层、6 头、词表 32000），不做再训练。

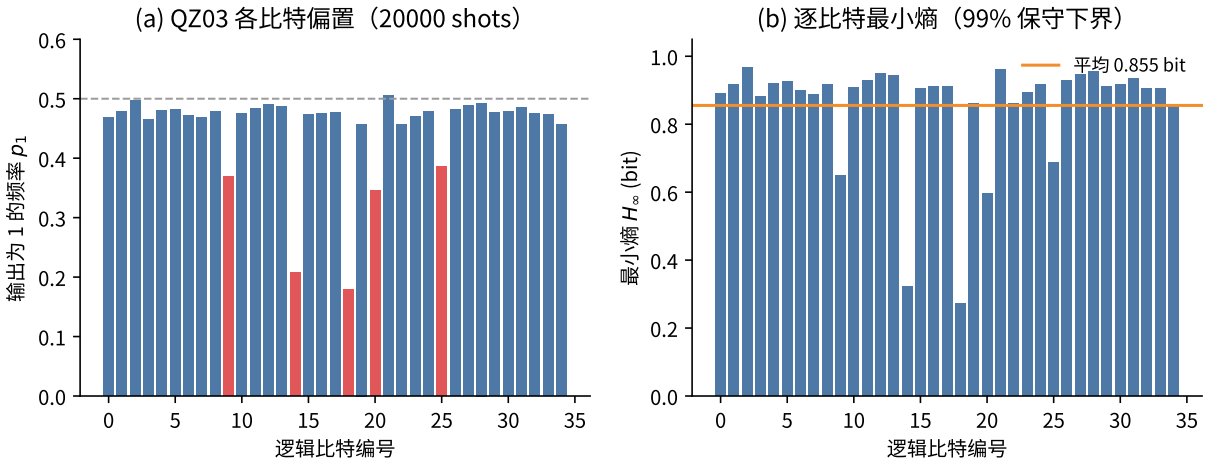


图 2: 提取前的原始偏置（a）与保守最小熵（b）：流水线据此确定 0.785 的提取率。红色为偏离 0.5 超过 0.05 的比特。

表 1: NIST SP 800-22 中 11 项检验的 p 值（$p \geq 0.01$ 视为通过）。

检验项	原始真机比特	Toeplitz 提取后
单比特频数 (Frequency)	0.0000	0.1007
块内频数 (Block Frequency)	0.0000	0.5482
游程 (Runs)	0.0000	0.7900
块内最长游程 (Longest Run)	0.0000	0.4954
二元矩阵秩 (Matrix Rank)	0.0681	0.0694
离散傅里叶谱 (DFT)	0.0000	0.6864
累加和-正向 (Cusum fwd)	0.0000	0.0225
累加和-反向 (Cusum bwd)	0.0000	0.1884
序列 (Serial) 1	0.0000	0.8584
序列 (Serial) 2	0.2475	0.8287
近似熵 (Approx. Entropy)	0.0000	0.7864
通过数	2/11	11/11

4.1 提取后的比特通过所测 11 项 NIST 检验

数据集为 QZ03 上的 20 条任务（每条 35 比特 $\times$ 1000 shots），共 2×10^4 次测量、7×10^5 个原始比特。

待消除的偏置。 原始比特带有读出偏置：总体“为 1”的频率为 0.452，最低的单比特 $p_1 = 0.179$（图 2a）。我们按 $H_\infty = -\log_2 \max(p_0, p_1)$ 逐比特估计最小熵，并对 $p_{\max}$ 取 99% 置信上界得到保守下界（图 2b）。保守的最小熵率为 0.855 bit/bit，提取率据此确定。

Toeplitz 提取。 取 $\varepsilon = 2^{-100}$、输入块 7000 bit，并留 5% 余量，每块输出 5496 bit，提取率为 0.785。对 100 个块共提取 5.496×10^5 bit，“为 1”的频率回到 0.5011。

随机性检验。 在等长前缀（5.49×10^5 bit）上，对原始比特与提取后比特分别运行 NIST SP 800-22 [6] 中的 11 项检验（表 1、图 3）。原始比特只通过 2 项，提取后 11 项全部通过。因此，QZ03 原始读出中的偏置可由标准提取流程消除，提取后的比特未被所测检验拒绝。

4.2 替换随机源不改变生成质量

我们比较三种随机源：量子随机数池（表中记为 QRNG）、MT19937（Python 标准库）与 CSPRNG（`os.urandom`）。三者统一量化为 16-bit 均匀数，接入 stories15M 的 top-p 采样（提示为“Once upon a time, there was a little”，温度 1.0，top-p 0.9）。

分布保真度。 对首个新 token 的固定分布 P，每种随机源各抽样 1.5×10^4 次。判断偏差的参照是理想采样本身的噪声底：同样次数的理想多项抽样与 P 的总变差（TV）距离均值为

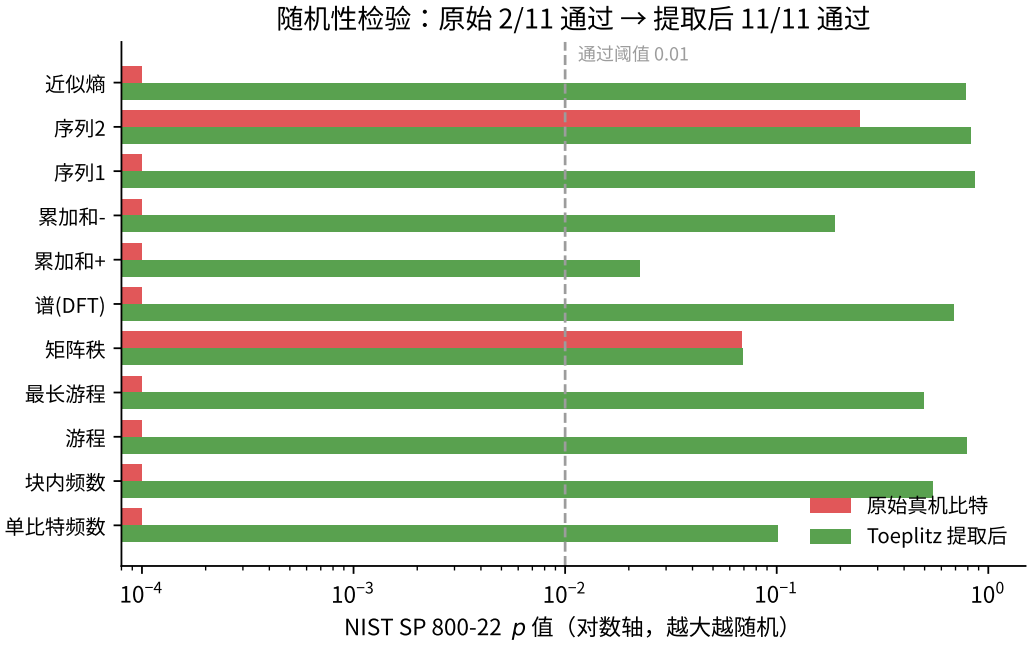


图 3: NIST SP 800-22 中 11 项检验的 p 值（对数轴），原始比特与 Toeplitz 提取后对照。

表 2: 分布保真度（$N = 1.5 \times 10^4$ 次抽样）。TV 的判据是理想采样噪声底，非源间比较。

随机源	卡方 p	KS p	总变差 TV
QRNG（QZ03）	0.562	0.875	0.0044
MT19937	0.944	0.113	0.0014
CSPRNG	0.361	0.505	0.0033
理想采样（参照）	—	—	0.0043 [0.0013, 0.0093]

0.0043，95% 区间为 [0.0013, 0.0093]。三种随机源的 TV 都落在该区间内，量子随机数池的 0.0044 与理想采样的典型值相当（表 2）。卡方与 KS 检验的 p 值均远大于 0.01；这些 p 值只用于判断是否通过，不用于比较随机源的优劣。

生成多样性。 每种随机源各生成 500 条长度为 20 的续写。三者的 distinct-n 与唯一续写占比相近，任意两种随机源之间的 token 频率相关系数为 0.997 – 0.998（表 3）。

这一结果与理论预期一致：采样是均匀数的确定性函数，而在最小熵估计成立的前提下，提取器保证池中比特与均匀分布的统计距离不超过 ε，因此生成分布与使用理想均匀数时的差别也不超过 ε。在所测条件下，把随机源换成 QZ03 未检出生成质量的差异。

4.3 抵御状态还原攻击

MT19937 驱动的生成可被逐字预测。 MT19937 是 Python 标准库与 PyTorch CPU 端的默认随机源，也是 NumPy 旧版接口的默认算法。它的内部状态是 624 个 32-bit 字：观测到 624 个连续输出后，逐个做 tempering 逆变换即可还原状态，进而预测此后的全部输出。在 LLM 中，这意味着攻击者能够预测模型将要采样的 token，并可能借此操纵生成。该攻击思路由文献 [1] 提出，我们在门模型 QPU 链路上复现它并量化其后果。

实测结果见图 4。采样源为 MT19937 时，攻击者观测 624 个 32-bit 输出后：

- 对随后 200 个随机数的预测命中率为 100%（200/200）；
- 对随后 30 个生成 token 的预测命中率为 100%（30/30），逐字复现了受害者的生成：“girl named Lily. She loved going to the park with her mom and dad⋯”。

量子随机数池使攻击退化为盲猜。 换用 QZ03 随机数池后，历史输出不再携带可还原的内部状态。攻击者对随后 token 的命中率为 73.3%，与只知道输出分布时盲猜的碰撞基线 $\mathbb{E}\sum_i P_i^2 =$

表 3: 生成多样性（每种随机源 500 条、长度为 20 的续写）。

随机源	distinct-1	distinct-2	distinct-3	唯一续写占比
QRNG（QZ03）	0.060	0.166	0.259	0.844
MT19937	0.058	0.162	0.249	0.828
CSPRNG	0.059	0.165	0.257	0.846

token 频率相关：QRNG – MT19937 0.997；QRNG – CSPRNG 0.998；MT19937 – CSPRNG 0.998

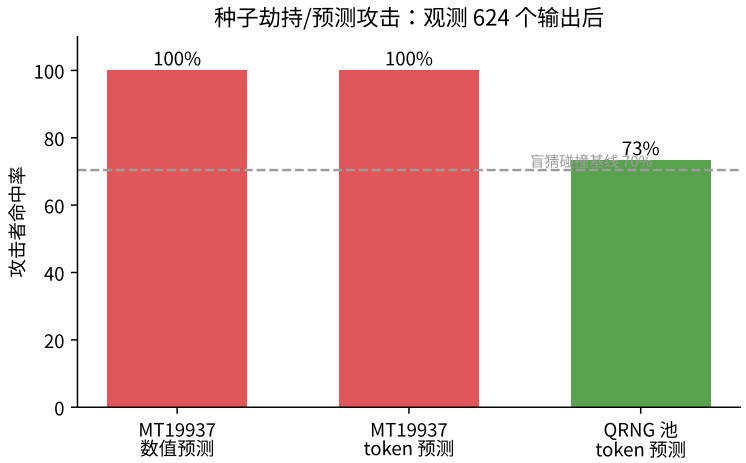


图 4: 状态还原（种子劫持）攻击。观测 624 个输出后，MT19937 驱动的采样被 100% 预测；换用量子随机数池后，攻击者命中率落在输出分布自身的盲猜基线（虚线）。

70.4% 无显著差异（二项检验 $p = 0.84$）[1]。

威胁模型与定位。 我们假设攻击者能观测历史输出，但不能读取池中尚未消费的比特。物理随机源没有可由输出还原的内部状态，也没有需要保密的种子（提取器种子本就公开），因此从源头消除了这一类攻击面；池中未消费的比特则应像密钥材料一样受到保护。CSPRNG 同样能抵御状态还原，其安全性建立在种子保密与计算困难性假设之上；量子随机数池的安全性来自测量这一物理过程。二者对应不同的信任模型。

4.4 吞吐与成本

我们根据 20 条任务的平台计量（平台返回的 `execution_time` 与墙钟时间戳）估计吞吐、延迟与成本（表 4）。

按纯执行时间计，单台 QZ03 的提取后产率可支撑约 1500 token/s 的解码采样，高于维持 1000 token/s 所需的产率；秒级的补池延迟在后台完成，不进入推理路径。本次实测的单价约为 ¥364/Mbit。

5 讨论

综合 § 4.1 – § 4.4 的结果，含噪、未纠错的 QPU 已能在 LLM 推理中承担一项不损失生成质量的功能。对已经拥有量子算力的算力中心，这意味着通用 QPU 无需新增专用硬件，就能在推理中承担确定的生产性负载。这一结论有以下边界：

- **随机性保证的来源。** 本文的随机性由 NIST SP 800-22 检验与 Toeplitz 提取器的剩余哈希引理保证，后者依赖最小熵估计的可靠性。基于随机电路采样的可认证随机性 [5] 要求电路规模足以抵抗经典模拟，并配合第三方验证；35 比特 QZ03 的电路可被经典模拟，因此本文不以可认证随机性为目标，二者是正交的两个方向。

[1] 碰撞基线由模型在该提示下的输出分布决定，与随机源无关。

表 4: QZ03 随机数产出的吞吐、延迟与成本（20 条任务实测）。

指标	数值
每条任务纯执行时间	1.15 ± 0.24 s（产 35000 原始 bit）
补池延迟（后台进行，不在推理路径上）	1.4 s（范围 1 – 2 s）
纯执行吞吐（原始 / 提取后）	3.06×10^4 / 2.40×10^4 bit/s
可支撑的解码采样速率	$\approx$ **1500 token/s**（16 bit/token）
维持 1000 token/s 所需原始产率	2.04×10^4 bit/s（低于实测产率，留有余量）
总成本 / 单位成本	¥200（5.50×10^5 提取 bit）/ ¥364 每 Mbit

- **提取器种子。** Toeplitz 矩阵的种子由操作系统 CSPRNG 生成（§ 3）。对端到端量子来源有要求的部署，可改用独立的可信随机源生成种子，流水线其余部分不变。
- **质量结论的适用范围。** 生成质量对照只覆盖一个提示与一组采样参数。结论能推广到其他模型与参数，依据是接口与 § 4.2 的理论论证：随机数池只向采样器提供均匀数，与模型的参数量和结构无关。因此 stories15M 足以验证从 QPU 到生成 token 的完整链路。
- **吞吐与成本。** 约 1500 token/s 按纯执行时间计算，未计入共享云平台的排队与调度开销。实测单价约 ¥364/Mbit，远高于专用光子 QRNG；本方案的价值在于让已有的通用 QPU 胜任这项负载，而不在于成本。

6 结论

解码采样是 LLM 推理中能够容忍量子硬件噪声的一环：噪声在这里表现为可被提取器消除的偏置与弱相关，而不构成计算错误。基于这一观察，量子随机数池让 35 比特的含噪云端 QPU QZ03 端到端驱动了预训练 LLM 的解码：提取后的比特通过所测 11 项 NIST 检验，生成质量与伪随机数相比未检出差异，基于输出的状态还原攻击退化为盲猜，按纯执行时间计单台设备可支撑约 1500 token/s。对已经拥有量子算力的算力中心，量子随机数池提供了一个轻量、对噪声鲁棒的接入点；其代价是远高于专用 QRNG 的单位成本，其随机性也经统计检验而非可认证。

A 计算路径的代价

本附录量化把前向计算也搬上量子线路的资源代价，支撑引言中关于计算路径当前不可行的判断。我们把 stories15M 的每一次矩阵-向量乘（含注意力中的 $q \cdot k$ 与 $p \cdot V$）写成量子干涉线路：用形如 $\frac{1}{\sqrt{2R}} \sum_j |j\rangle(|0\rangle|\hat{x}\rangle + |1\rangle|\hat{m}_j\rangle)$ 的叠加态，对辅助比特施加 Hadamard 门后测量，$P(j,0) - P(j,1) = \langle \hat{x}|\hat{m}_j\rangle / R$ 即给出内积（RMSNorm 增益与 RoPE 旋转并入权重）。在 Qiskit Aer 上，使用精确概率时 30 个 token 全部与经典计算逐字一致；每行 10^6 shots （每个位置 4.4×10^{10} shots）时仍然全部一致，降到 10^5 shots 时从第 25 个 token 起出现偏离。逐字复现所需的 shots 达 10^{10} 量级，这是计算路径当前不可行的主要原因。

在 QZ03 上，我们实测了第 0 层第 0 个注意力头的打分（48 维内积拆成 12 段 4 维 Hadamard 测试，10 段并行）：单段 4 维余弦与理想值的相关系数为 0.90；合成的 48 维打分相关系数为 0.52，注意力分布的总变差为 0.55；而送回模型后，下一个词分布与精确值的总变差仅为 0.017，说明在这一例中，单个低层注意力头的误差被模型吸收。但即便单头误差可被吸收，逐字复现整条前向所需的 shots 规模仍远超解码随机数。两相对照，解码随机数池是当前更直接可用的接入点。

复现

配套代码与数据随本文提供：真机 QRNG 原始比特（`qz03_qrng_raw.json`，含 20 条任务 ID 与时间戳）、随机性分析与提取（`analyze_qrng.py`、`nist_sts.py`）、采样对照（`qsample.py`）、攻防演示（`attack.py`）、吞吐成本（`throughput.py`）、全前向量子化（`qfull.py`）。真机平台：逻辑比特云（`cloud.logicalqubit.com`，SDK `lqcloud`）。

参考文献

[1] Seed Hijacking of LLM Sampling and Quantum Random Number Defense. arXiv:2605.08313 (2026).

[2] Quantum exordium for natural language processing: sampling on decoders, validated on QuTech Tuna-9 (T-9) hardware（8 词词表玩具演示）.

[3] Quantum-random vLLM sampler (qr-sampler). `github.com/alchemystack/Quantum-random-vLLM-sampler`.

[4] K. Tamura, Y. Shikano. Quantum Random Numbers generated by the Cloud Superconducting Quantum Computer. arXiv:1906.04410 (2019).

[5] Certified randomness using a trapped-ion quantum processor (JPMorganChase & Quantinuum H2, 56 qubits). Nature (2025).

[6] A. Rukhin et al. A Statistical Test Suite for Random and Pseudorandom Number Generators. NIST SP 800-22 Rev. 1a (2010).

[7] M. Turan et al. Recommendation for the Entropy Sources Used for Random Bit Generation. NIST SP 800-90B (2018).